• Distributed System Kfaka

- 問題(目的)與背景
- 架構解析
 - Kafka Producer's view
 - Kafka Consumer's view
 - Kafka Zookeeper Broker's view
- 技術實作與心得
- 評論
- 結語
- 分工

Distributed System Kfaka

- 組員
 - 108753208 葉冠宏
 - 109753209 李庭慶
 - 110703065 詹松霖
 - 110753113 張皓博
 - 110753147 王盛泰
 - 110753161 鄭仁傑

問題(目的)與背景

Briefly explain the core idea of the technology

Kafka建立一個數據中心來作為Message Queue Middleware,它的高產出及低延遲可以有效防止突發性的大數據湧入,並且因為將資訊都傳入Kafka處理,可以適當的解放其他系統的設計靈活度。

該分散式系統/技術的應用場景 (Example),用來說明:

在什麼場何用來解決什麼問題?

沒有它又如何?

Kafka 作為一個速度快的分散式event streaming platform,他可以使大量的資料持續的在正確的時間流到正確的位置。 其中心為Broker的構造也使Producer與Consumer不必知道互 相的位置,可輕鬆替換系統中的組件。很多公司會使用它來做即時的資料串流或反饋。

上述特性使Kafka常用在以下情景

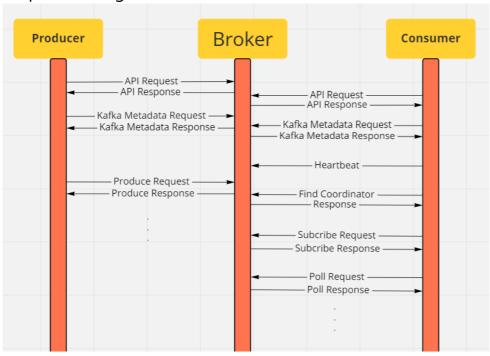
- 即時的付款與金融交易。如證券交易所與銀行
- 追蹤跟監控卡車,貨物。如物流業
- 持續的搜集用戶的操作並做即時的反饋。如netflix的推薦下一部的功能即使用到Kafka。

若沒有中心的Broker構造,分散式系統中的每個組件就必須知道互相的位置,整個系統的耦合度極高。即便自己寫了個簡易的Broker,它掛掉整個系統就癱瘓了。但Kafka能讓各Broker間可以相互協調、取代,使穩定度大幅提升。

架構解析

Kafka中的節點可以分為三種,分別是 Broker, Producer, Consumer。其運行模式大致為下圖所示。

Sequence Diagram



可大致理解為由Consumer先向Broker訂閱某個topic。當任—Producer向這個topic發布消息的時候,所有訂閱此topic的Consumer都能收到此消息。

Kafka Producer's view

以Producer的觀點來分析Kafka,著重在Producer的核心功能 send

Future<RecordMetadata> send(ProducerRecord<K, V> record, Callback callback);

- 當send被call時,Producer會先向Cluster發送API version 與Kafka metadata的請求。做protocol的確認與獲得主要 負責該topic,partition 的Broker的資訊。取得的資料會被 存進 ProducerMeta,方便之後的send可以直接由此處調 用所需資料。
- 接著要發送的訊息會被暫存到RecordAccumulator,當暫存的record總大小超過ProducerConfig所設定的BATCH_SIZE,或是經過設定的LINGER_MS時長後,會把RecordAccumulator中的records包裝成一個ProduceRequest發送到Broker。Broker在處裡好訊息後會回傳一個Producer Response,讓Producer可在CallBack中對error做處裡。

若是想立即發送訊息也可以使用 flush() 來將當前 Accumulator中的訊息發出

PARTITION

Kafka有類似於Mqtt的sharding的概念,叫做partition。可以把一個topic切成多段處裡,使系統可以平行擴充,架設多個Broker來分擔壓力。

如何決定一個訊息該發到哪個partition?

Producer可以在send的時候"選擇"加入partition number 以及 key 的參數。若有設定partition number,則該訊息就會被發到對應編號的partition。若沒有partition number,則由 key的hash決定。若只單純發送value的話,一個producer就會流輪發送到不同partition。

Kafka Consumer's view

以Consumer的觀點來分析Kafka·著重在Consumer核心功能Subscribe(), Poll()以及Kafka透過Rebalance來進行有效率的資源分配。會先透過Class Diagram對於Kafka Consumer整體架構有初步的了解,整體的類別圖會著重在

KafkaConsumer與核心功能Class間的繼承、實作介面、呼

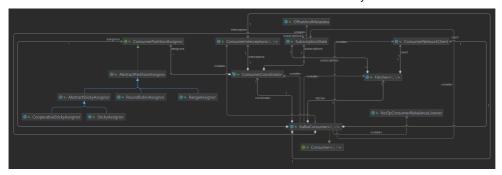
- 叫,能有助於對Kafka Consumer的理解以及往後的實作細
- 節。Rebalance功能會使用Sequence Diagram時序圖來表
- 示,因為觸發Rebalance事件需要類似Topoic中Partitions數

量改變·Consumer Group中有新成員加入或退出·這樣的事件都是涉及時間及元件之間的互動·因此會用較直觀的時序圖來表達這樣的關係。

CLASS DIAGRAM

Class Diagram透過IntelliJ IDEA內建的UML所繪製。下圖所呈現的Class Diagram並非是與Consumer所有相關聯的功能都繪製在此圖。此圖著重在實作Consumer介面的KafkaConsumer中核心功能。

- ConsumerCoordinator:繼承 AbstractCoordinator介面,管理與consumer coordinator相關的功能例如Group Registration, Group/Leader Selection, State Assignment 功能。且透過此才能與ConsumerGroupMetadata溝通。
- ConsumerPartitionAssignor:用來定義Consumer partitions如何分配的介面,Kafka四種分配策略也是繼承此介面分別是RangeAssignor, RoundRobinAssignor, StickyAssignor, CooperativeStickyAssignor。
- ConsumerNetworkClient:提供Consumer與網路接取的相關功能
- Fetcher: 負責向Broker獲取訊息的相關功能且是Threadsafety
- NoOpConsumerRebalanceListener:實作
 ConsumerRebalanceListener callback interface,當觸發
 Rebalance時所採取的行動,前提是Consumer採用Kafka
 auto-manage group membership才適用。
- SubscriptionState:用來追蹤紀錄Consumer的topics, partitions, and offsets
- OffsetAndMetadata:當offest被確認後允許使用者提交額外的元資料(哪個節點哪個時間)。
- ConsumerInterceptors < K, V > : 存有list傳入custom interceptors,可以在poll(),offest傳回成功與否前進行攔 截及修改。



SUBSCRIBE細節解析

Kafka Scbscribe Source code

(https://github.com/apache/kafka/blob/7c8c65fc54b9eb0386787632ff8315e097d99818/clients/src/main/java/org/a

pache/kafka/clients/consumer/KafkaConsumer.java#L956-L980)

在這之前會先有初始化設置配置,傳入的參數會是Key Value。包括Heartbeat頻率,是否要自動更新Offset,Key Value的反序列化,Timer時間等等。

- 1. 先確定Consumer在不在且取得lock
 - o acquireAndEnsureOpen();
- 2. 檢查GroupID存不存在
 - o maybeThrowInvalidGroupIdException();
- 3. 訂閱的Topic不能是empty or null
 - if (Utils.isBlank(topic))
- 4. 檢查有無Partition assigner
 - o throwIfNoAssignorsConfigured();
 - private List<ConsumerPartitionAssignor> assignors;

- 裡面會去檢查 if (assignors.isEmpty())
- 如果是空的會 throw new IllegalStateException

5. 實際訂閱動作

- o fetcher.clearBufferedDataForUnassignedTopics(top ics);
- Set<TopicPartition> currentTopicPartitions = new HashSet<>();
- o TopicPartition在kafka/common/TopicIdPartition.java
- 把新訂閱的加到 currentTopicPartitions.add()
- 把非此次的訂閱的Topic從buffer中清掉

6. 訂閱的Topic(s) 寫入log

o log.info()

7. 更新時戳

- o if (this.subscriptions.subscribe(new HashSet<>
 (topics), listener))
- requestUpdateForNewTopics()
- Override the timestamp of last refresh to let immediate update

8. 釋放掉lock

- o release()
- Release the light lock protecting the consumer from multi-threaded access.

POLL 細節解析

Kafka Poll Source code

(https://github.com/apache/kafka/blob/7c8c65fc54b9eb0386787632ff8315e097d99818/clients/src/main/java/org/a

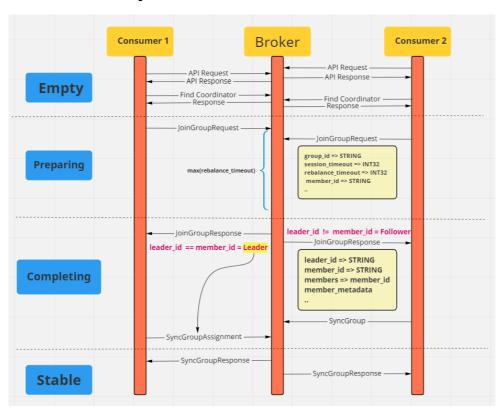
pache/kafka/clients/consumer/KafkaConsumer.java#L1226-L1273)

```
final boolean includeMetadataInTimeout) {
                  this.kafkaConsumerMetrics.recordPollStart(timer.currentTimeMs());
                  if (this.subscriptions.hasNoSubscriptionOrUserAssignment()) {
                      throw new IllegalStateException("Consumer is not subscribed to any topics or assigned any partitions"):
                      client.maybeTriggerWakeup();
                      if (includeMetadataInTimeout) {
                          while (!updateAssignmentMetadataIfNeeded(time.timer(Long.MAX_VALUE), true)) {
                              log.warn("Still waiting for metadata");
                       final Fetch<K, V> fetch = pollForFetches(timer);
1248
                       if (!fetch.isEmpty()) {
                           // NOTE: since the consumed position has already been updated, we must not allow
                           // wakeups or any other errors to be triggered prior to returning the fetched records.
                           if (fetcher.sendFetches() > 0 || client.hasPendingRequests()) {
                           if (fetch.records().isEmpty()) {
                                log.trace("Returning empty records from `poll()` "
                           return this.interceptors.onConsume(new ConsumerRecords<>>(fetch.records()));
                   } while (timer.notExpired());
                   return ConsumerRecords.empty();
                   this.kafkaConsumerMetrics.recordPollEnd(timer.currentTimeMs());
```

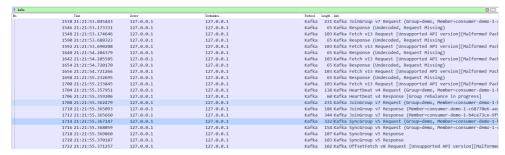
- 1. 先確定Consumer在不在且取得lock
 - o acquireAndEnsureOpen();
- 2. 紀錄Consumer poll的行為
 - 紀錄此次的poll時間及距離上次poll的時間
 - o this.kafkaConsumerMetrics.recordPollStart(timer. currentTimeMs());
- 3. 檢查Consumer有沒有訂閱主題
 - hasNoSubscriptionOrUserAssignment()
 - 如果沒有會丟出 IllegalStateException()
- 4. 每個Poll都要先確保對外連接的client是否被喚醒
 - o client.maybeTriggerWakeup();
- 5. 嘗試更新分配的metadata且不會影響到Join Group的 Timer
 - o default是true includeMetadataInTimeout
 - updateAssignmentMetadataIfNeeded(timer, false);

- 6. 先確保fetch到的record數量不是0
- 7. 因為此次回傳的值都是上次Fetch到的內容
 - 此段在做檢查並讓效率提高作Pipeline
 - 符合的話會在此次送出回傳給下一次的Fetch
- 8. 如果fetch到的records是empty寫入log
 - 這可能是因為某些因素被中止而導致的
- 9. 回傳fetch到的records
 - Default每次最大fetch的record數量500
- 10. 重複5-10直到Timer過期
- 11. 回傳一個空的Key Value值
- 12. 釋放掉lock
 - o release()
- 13. 將此次的Poll的衡量指標記錄到kafkaConsumerMetrics

REBALANCE SEQUENCE DIAGRAM



Rebalance機制運用兩個不同的Consumer加到同一個Consumer Group的情況來解釋且有用Wireshark Trace過程再將此過程透過Miro工具繪製。



Consumer Group狀態為Empty

- 1. Consumer會先向Broker要後續溝通所需的API及版本
- 2. Consumer會收到Broker所回應的API版本
- 3. Consumer會去找一個特定Broker作為coordinator負責監 控再加入Consumer Group後的相關事項(Hearbeat,啟動 Rebalance等)
- 4. Consumer會收到回應的特定coordinator

Consumer Group狀態為Preparing Balance

- 5. Consumer會去申請加入ConsumerGroup
 - group id:要加入的group id
 - session_timeout : 不用heartbeat也能確保Consumer 還在
 - rebalance_timeout:用來等Consumer重新加入群組 的時間

因此Broker在最大的rebalance_timeout時間後就會把 Response送出

Consumer Group狀態為Completing Balance

- 6. Consumer會收到Broker的JoinGroup回應
 - 通常第一個送要JoinGroupRequst的消費者會是 Leader
 - 可以由leader_id及member_id去判斷為Leader或 Follower
 - 內有各組員訂閱狀況
- 7. Follower會送出SyncGroup給Broker
 - 但內容為空意思在等待leader分配後的結果
- 8. Leader會收集JoinGroup回應後做出分配並傳給Broker
 - 分配策略就涉及到上面所提 ConsumerPartitionAssignor介面

RangeAssignor, RoundRobinAssignor,
 StickyAssignor, CooperativeStickyAssignor

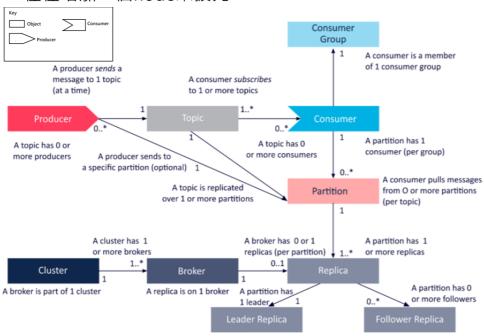
Consumer Group狀態為Stable

10. 最後每位Consumer會收到被分配的狀況

直到下次觸發Rebalance事件發生Stable狀態才會改變

Kafka Zookeeper Broker's view

- 動機: Zookeeper 做好了分散式系統的協調服務讓分散式系統直接引用,免去從頭開始實作協調服務的麻煩。
- Reliability: Zookeeper 可以在有些節點fail 時,依然持續 運作。
- Simplicity:Zookeeper 可以藉由shared hierarchical namespace 協調process。
- Speed: Zookeeper 可以快速的處理Reading的 workloads。
- Scalability:Zookeeper是horizontally scalable。可以藉由 僅僅增加一個node來擴充。



BROKER 在ZOOKEEPER中的註冊

- 為了記錄Broker的註冊訊息,在Zookeeper上專門創建了屬於Kafka的一個節點,其路徑為/brokers
- Kafka的每個Broker啟動時,都會到Zookeeper中進行註冊,告訴Zookeeper其 **broker.id**(http://broker.id)。而在整個群集中,broker.id全局唯一,並在Zookeeper中創建其屬於

自己的節點,其節點路徑為/brokers/ids/{**broker.id**}。

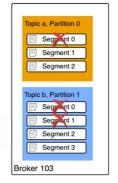
- 創建完節點後,Kafka會將該broker的broker.name及其 port記錄到該節點。
- 另外,該broker節點屬性為臨時節點,當broker失效時, Zookeeper會刪除該節點,這樣我們就可以很方便的監控 到broker節點的變化及rebalance。
- 我們可以設定broker中的data要儲存多久,因為維持越久的data,會花費越多的成本來維護。

Data Retention Policy

How long do I want or can I store my data?

- How long (default: 1 week)
- Set globally or per topic
- · Business decision
- Cost factor
- Compliance factor → GDPR



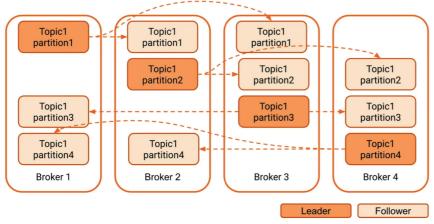


Retention Policy

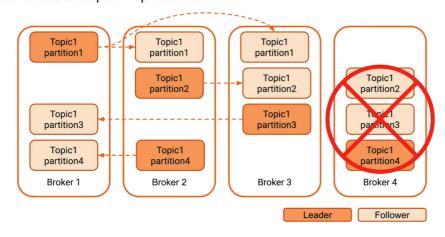
TOPIC 在ZOOKEEPER中的註冊

- 在Kafka中,所有topic及broker的對應關係都由 Zookeeper進行維護。在Zookeeper中,建立專門的節點 來記錄這些訊息,其節點路 為/brokers/topics/{topic_name}。
- 為了保障數據的可靠性,每個Topic的partitions 實際上是存在備份的,並且備份數量由Kafka機制中的replicas來控制。為了保障數據的一致性,Kafka為每一個partition找一個節點作為leader,其餘備份作為follower。當producerpush的訊息寫入partition時,作為leader的broker會將訊息寫入自己的分區,同時還會將訊息複製到各個follower,實現同步。而follower只是跟隨leader的變動去更新資料。如果某個follower掛掉,leader會再找一個替代,並同步訊息。如果leader掛了,follower們會選舉出一個新的leader代替,繼續服務,這些都是由Zookeeper完成的。

Partition Leadership & Replication



Partition Leadership & Replication



CONSUMER 在ZOOKEEPER中的註冊

當新的consumer 註冊到Zookeeper時,Zookeeper會創建專用的節點來保存相關的訊息,其節點路徑為 ls/consumers/{group_id}。其節點下有三個子節點,分別為 [ids, owners, offsets]。

- ids節點:紀錄該消費組中正在消費的consmer。
- owners節點:紀錄該消費組消費的topic訊息。
- offsets節點:紀錄每個topic的每個分區的offset。

借助Zookeeper實現Rebalance Sequence

Consumer在消費時只需制定topic,借助Zookeeper可以根據partition的數量和consumer的數量做到均衡的動態配置。Consumer在啟動時會到Zookeeper下以自己的conusmer-id 創建臨時節點/consumer/[group-id]/ids/[conusmer-id],並對/consumer/[group-id]/ids 註冊監聽事件。當consumer發生變化時,同一個group的其他consumer會得到通知。

紀錄Consumer進度的offset

在consumer對指定的訊息進行消費的過程中,需要定時的將 partition消息的消費進度offset 記錄到Zookeeper中,以便在 該consumer進行重啟或者其他consumer重新接管該消息

partition的消費權後,能夠從之前的進度開始繼續進行消費。Offset 在Zookeeper中由一個專門的節點進行紀錄,其節點路為

/consumers/[group_id]/offsets/[topic]/[broker_id-partition_id]

紀錄consumer與partition的關係

在Kafka中,規定了每個partition只能被同組的一個消費者進行消費。因此,需要在Zookeeper上記錄下partition與consumer之間的關係。每個consumer一旦確定了對一個partition的消費權利,需要將其consumer ID寫入到Zookeeper對應消息分區的臨時節點上。例如:/consumers/[group_id]/owners/[topic]/[broker_id-partition_id]

其中,[broker_id-partition_id] 就是一個消息分區的標示, 節點內容就是該消息分區consumer的consumer ID。

BROKER 啟動流程

broker 是從路徑 core/src/main/scala/kafka/Kafka.scala 開始執行,會以讀入的 properties 檔來啟動不同的 broker,如果以 config/server.properties 的範例設定來設定,會採用 Zookeeper 來同步 replica node ,若以 config/kraft/server.properties 的範例設定設定時,則會以 Raft 的方式來同步。以 Zookeeper 來設定則會產生 KafkaServer 的物件,KafkaServer 的主要成員如下圖

KafkaServer +_zkClient: KafkaZkClient + dataPlaneRequestProcessor: KafkaApis + dataPlaneRequestHandlerPool: KafkaRequestHandlerPool + controlPlaneRequestHandlerPool: KafkaApis + controlPlaneRequestHandlerPool: KafkaRequestHandlerPool + socketServer: SocketServer +_replicaManager: ReplicaManager +_logManager: LogManager

_zkClient 為 zookeeper server 的 client 端,會對其他相同連線到 zookeeper server 的 replica node 發送同步,dataPlaneRequestProcessor、 dataPlaneRequestHandle rPool、 controlPlaneRequestProcessor、 controlPlaneRequestHandlerPool、 socketServer 則是處理從網路來的請求,一開始會將 RequestProcessor 以及 RequestHandlerPool 註冊進 sockeServer 的 data plane 以及 control plane,當有新的 Request 時, socketServer 便會從 RequestHandlerPool 產生對應的 RequestHandler 並執

行,_replicaManager 是管理節點的 partition,依照 partition 的同步狀況來決定是否繼續同步該 partition, partition 內容紀錄則是靠 _logManager 來完成, _logManager 會根據設定檔中的 log.dirs 的路徑存放 consumer、topic、等與 broker 相關的資料。以預設的 config/server.properties 來說,會存放在 /tmp/kafkalogs。

技術實作與心得

Demo Source Code

(https://github.com/SpeedReach/KafkaTesting/tree/main/src/main/java/team/antipython/kafkatest) 首先把Cluster架起來,開啟兩個terminal,分別運行 Zookeeper 與 1個Kafka Broker。 在server.properties中設定 broker的 ip與host, 這邊設定 localhost:9092

```
.\zookeeper-server-start.bat .\zookeeper.properties .\kafka-server-start.bat .\server.properties
```

Cluster架好後來要創建Topics,這邊創建一個名叫 DemoTopic的Topic

```
Admin admin = Admin.create(Collections.singletonMap(AdminClientConfig.BOOTSTRAP_SERVERS_
try {
    Set<String> existingTopics = admin.listTopics().names().get();
    if(!existingTopics.contains("DemoTopic")){
        /*
        Partitions 是該topic的訊息可以分成幾類
        ReplicationFactors 是副本數 必須小於 Broker數量
        由於demo只有一個 broker所以只有一個副本
        */
        int partitions = 3;
        short replicationFactors = 1;
        Set<NewTopic> newTopics = Collections.singleton(new NewTopic("DemoTopic",partiti admin.createTopics(newTopics).all().get();
    }
} catch (ExecutionException | InterruptedException e) {
            e.printStackTrace();
}
```

接著寫Consumer來訂閱DemoTopic的訊息

```
Properties props = new Properties();
props.setProperty("bootstrap.servers", "localhost:9092");
props.setProperty("group.id", "demo");
props.setProperty("enable.auto.commit", "false");
props.setProperty("key.deserializer", "org.apache.kafka.common.serialization.String[
props.setProperty("value.deserializer", "org.apache.kafka.common.serialization.Strirfinal Consumer<String,String> consumer = new KafkaConsumer<>(props);
consumer.subscribe(Collections.singleton("DemoTopic"));
while (true){
    ConsumerRecords<String,String> records = consumer.poll(Duration.ofMillis(100));
    records.forEach(record->{
        System.out.println("Topic: "+record.topic() + " ,Value: "+record.value());
    });
}
```

接著來寫Producer發布一條"SomeMessage"的訊息到 DemoTopic

```
Properties props = new Properties();
props.put(ProducerConfig.BOOTSTRAP_SERVERS_CONFIG, "localhost:9092");
props.put(ProducerConfig.ACKS_CONFIG, "all");
props.put(ProducerConfig.RETRIES_CONFIG, 0);
props.put("linger.ms", 1);
Producer<String, String> producer = new KafkaProducer<>(props);

producer.send(new ProducerRecord<>("DemoTopic", "SomeMessage"), (recordMeta,err)->{
    System.out.println("Sent message to "+recordMeta.topic)
});
producer.flush();
```

先執行Admin

(https://github.com/SpeedReach/KafkaTesting/blob/main/src/main/java/team/antipython/kafkatest/Init.java#L25-L59)創建Topic後,再執行**Producer**

(https://github.com/SpeedReach/KafkaTesting/blob/main/src/main/java/team/antipython/kafkatest/Subscriber.jav a#L22-L42),可看到Consumer輸出

Topic: DemoTopic ,Value: SomeMessage

Producer則輸出

Sent message to DemoTopic

評論

- Identify a context where this technology is not appropriate and justify your answer
 - 我需要一個分散式系統,在晚上時Publisher發出「晚上了」給Subscriber,早上時發出「早上了」,且 Subscriber數量不超過100個,此時使用Kafka就顯得 大材小用了。
 - 當每筆data都需要保存至少10年以上,因為Kafka需要複製儲存副本,此時使用Kafka就需要龐大的儲存成本。
- Identify a context where this technology is appropriate and justify your answer
 - 今天我需要在將data傳給Consumer之前先進行一次 處理,此時就可以使用Kafka,將Producer傳進來的 data先給data handlers處理後再儲存。

結語

Kafka設計的初衷在於處理即時資料提供一個統一、高吞吐、低延遲的平台,因此設計的重點更著重在效能與擴充性,但也包括了MQ本來就具有的優點,例如:不同步的溝通、可靠性等等,底下分別提到這些特性。

負載平衡:透過partition的設計,producer發布訊息在不同broker上,以partition為單位,可以依據partition目錄的訊息量、broker目前的負載做負載平衡。

減少耦合:透過topic的設計,producer、consumer只要關心borker在哪,以及所選的topic即可,不須知道對方的資訊。順序保證:在partition中,又切割成segment為儲存單位,收到的訊息皆以循序的方式儲存,可以確保partition內部的順序儲存;對於consumer來說,由於一個訊息只能有一個consumer消耗,因此當consumer數量大於等於partition時,還可以再確保收到的訊息順序。

不同步溝通:kafka設計中允許In-Sync Replicas以外的副本不必同步更新,透過設定min.insync.replicas參數以及In-Sync Replicas數目,在可靠度與效率之間可以有彈性的調整。 擴展性:可依照需求增加或減少partition。

可恢復性:在partition中儲存的訊息中,透過HW機制以及broker定時向zookeeper更新參數,當某些broker故障時,因為有副本存在,並不影響其他節點運作,而在系統恢復之後,可以利用副本以及HW恢復遺失的資料。

緩衝:利用message queue做為緩衝,consumer採用pull的方式獲取資料,可以照顧到不同效率的consumer設備,使producer、consumer不必互相等待。

高速存取:直接存取磁碟而不必先複製到記憶體,且存取代價為O(1)。

Kafka適合應用在大部分大規模服務的情況,且consumer可以以pull方式接收訊息;反之,若只是應用在一般的整合服務(例如企業應用整合),並不會有太多節點,訊息量可能也不大,只是為了整合不同系統,那使用kafka就顯得小題大作,浪費了可擴充性、大吞吐量等特性。

分工

- 問題(目的)與背景: 仁傑
- 架構解析:

○ Broker: 庭慶 冠宏

○ Consumer: 皓博

○ Producer: 詹霖

• 技術實作與心得:詹霖

● 評論: 仁傑

● 結語:盛泰

• 書面資料